# MODELO 3 - Avaliação dos Modelos de marchine learning.

```
In [1]: %matplotlib inline
In [2]: # Importa as bibliotecas
        import pandas
        import matplotlib.pyplot as plt
        import numpy
        #from pandas.tools.plotting import scatter_matrix
        from pandas.plotting import scatter_matrix
        import seaborn as sb
        from sklearn.model selection import train test split,cross val score
        from sklearn.preprocessing import Normalizer
        #Logistic Regression
        from sklearn.linear_model import LogisticRegression
        from sklearn.metrics import roc_auc_score , roc_curve, auc ,accuracy_score,recall_score, preci
        sion_score,f1_score
        import statsmodels.api as sm
        from sklearn.metrics import confusion_matrix
        # Load Libraries
        import pandas as pd
        from sklearn.tree import DecisionTreeClassifier # Import Decision Tree Classifier
        from sklearn import metrics #Import scikit-learn metrics module for accuracy calculation
```

# 1) Carregando os dados de treino e teste para avalição do modelo

```
In [7]: dfContador =pandas.DataFrame(list(y_train), columns = ['genero'])
    contagem = dfContador.groupby('genero').size()
    print(contagem)

genero
    0    1108
    1    1108
    dtype: int64

In [8]: dfContador =pandas.DataFrame(list(y_test), columns = ['genero'])
    contagem = dfContador.groupby('genero').size()
    print(contagem)

genero
    0    476
    1    476
    dtype: int64
```

# 2) carregando o modelo Random Forest

```
In [9]: from sklearn.ensemble import RandomForestClassifier
    rf_model = RandomForestClassifier(random_state=1,n_estimators=100,min_impurity_decrease=0.05)
```

## Treinamento e teste do modelo: Random Forest.

# Modelo de avaliação de métricas.

## Precisão Geral (Accuracy)

```
In [12]: #get accuracy
rf_accuracy_testdata = metrics.accuracy_score(y_test, rf_pred)
```

```
In [13]: #print accuracy
print ("Accuracy: {0:.4f}".format(rf_accuracy_testdata))
RF_Accuracy = metrics.accuracy_score(y_test, rf_pred)
print(RF_Accuracy)
```

Accuracy: 0.8918 0.8918067226890757

#### Matriz de confusão: Random Forest

```
In [14]: import plot as plot
    cm=confusion_matrix(y_test,rf_pred)
    #Plot the confusion matrix
    plt.rcParams['figure.figsize'] = (10,5)
    sb.set(font_scale=1.5)
    sb.heatmap(cm, annot=True, fmt='g')
    plt.show()
```



## **Metricas Report: Random Forest**

0 0.86 0.94 0.90 476 0.94 1 0.84 0.89 476 0.89 952 accuracy 0.90 0.89 0.89 952 macro avg weighted avg 0.90 0.89 0.89 952

```
In [16]: cm=confusion_matrix(y_test,rf_pred)
    confusion_matrix_lda = pandas.DataFrame(cm, index = ['Negativos','Positivos'], columns = ['Pre
    visão dos negativos','Previsão dos positivos'] )
    confusion_matrix_lda['Total'] = 1
    confusion_matrix_lda['Total'][0] = cm[0][0] + cm[0][1]
    confusion_matrix_lda['Total'][1] = cm[1][0] + cm[1][1]
```

```
In [17]: confusion_matrix_lda
```

Out[17]:

|           | Previsão dos negativos | Previsão dos positivos | Total |
|-----------|------------------------|------------------------|-------|
| Negativos | 449                    | 27                     | 476   |
| Positivos | 76                     | 400                    | 476   |

```
print(confusion matrix lda)
In [18]:
                    Previsão dos negativos Previsão dos positivos
                                                                     Total
         Negativos
                                        449
                                                                 27
                                                                       476
         Positivos
                                         76
                                                                400
                                                                       476
         TP = confusion matrix lda['Previsão dos positivos'][1]
         dfTP = pandas.DataFrame(TP, index = ['Positivos verdadeiros'], columns = ['Quantidade acertos'
         ] )
In [20]: TN = confusion matrix lda['Previsão dos negativos'][0]
         dfTN = pandas.DataFrame(TN, index = ['Verdadeiro Negativo'], columns = ['Quantidade acertos']
         )
In [21]:
         FP = confusion_matrix_lda['Previsão dos positivos'][0]
         dfFP = pandas.DataFrame(FP, index = ['Falso Positivo'], columns = ['Quantidade acertos'] )
In [22]:
         FN = confusion_matrix_lda['Previsão dos negativos'][1]
         dfFN = pandas.DataFrame(FN, index = ['Negativos Falsos'], columns = ['Quantidade acertos'] )
In [23]:
         rfSpecificity = TN / float(TN + FP)
         dfSpecificity = pandas.DataFrame(rfSpecificity, index = ['Specificity'], columns = ['resultad
         o'])
In [24]: dfSpecificity
Out[24]:
                   resultado
          Specificity
                   0.943277
In [25]: rfRecall= recall score(y test, rf_pred)
         print(rfRecall)
         0.8403361344537815
In [26]: print(TP / float(TP + FP))
         print(precision_score(y_test, rf_pred))
         rfPrecision = precision_score(y_test, rf_pred)
         0.936768149882904
         0.936768149882904
In [27]: | rfF1Score = 2 * rfPrecision * rfRecall / float(rfPrecision + rfRecall)
         print(rfF1Score)
         0.8859357696566998
In [ ]:
In [ ]:
```

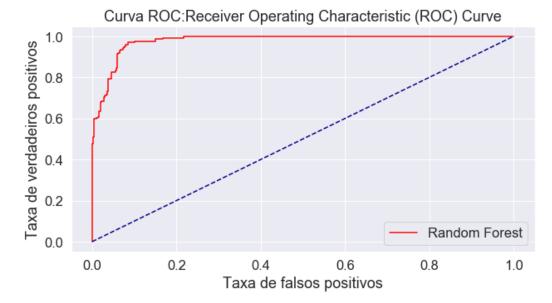
#### **Curva ROC: Random Forest**

Uma curva ROC é uma forma comumente usada para visualizar o desempenho de um classificador binário, significando um classificador com duas classes de saída possíveis. A curva plota a Taxa Positiva Real (Recall) contra a Taxa Falsa Positiva (também interpretada como Especificidade 1).

```
In [28]: rf_pred_prob = rf_model.predict_proba(X_test)[:, 1]
In [29]: rf_fpr, rf_tpr, thresholds = roc_curve(y_test, rf_pred_prob)
```

```
In [30]: def plot_roc_curve(fpr, tpr,nome='ROC'):
    plt.plot(fpr, tpr, color='red', label=nome)
    plt.plot([0, 1], [0, 1], color='darkblue', linestyle='--')
    plt.xlabel('Taxa de falsos positivos')
    plt.ylabel('Taxa de verdadeiros positivos')
    plt.title('Curva ROC:Receiver Operating Characteristic (ROC) Curve')
    plt.legend()
    plt.show()
```

```
In [31]: plot_roc_curve(rf_fpr, rf_tpr,'Random Forest')
```



## AUC (área sob a curva) da Curva ROC : Random Forest

AUC ou Area Under the Curve é a porcentagem do gráfico do ROC que está abaixo da curva. AUC é útil como um único número de resumo do desempenho do classificador.

# Carregando o modelo Máquina de vetores de suporte SVM

```
In [35]: from sklearn.svm import SVC
svm_model = SVC(kernel='linear', C=45, random_state=2 ,probability=True,coef0=0.3)
#kernel='linear'
```

#### Treinamento e teste do modelo: SVM.

## Modelo de avaliação de métricas.

## Precisão Geral (Accuracy): SVM

```
In [38]: print(f"accuracy score: {accuracy_score(y_train, svm_pred):.4f}\n")
svm_accuracy_testdata = accuracy_score(y_train, svm_pred)
accuracy score: 0.9887
```

### Matriz de confusão: SVM

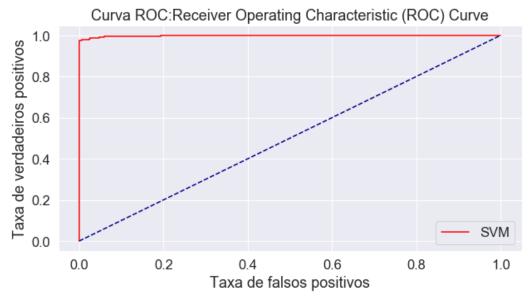
```
In [39]:
         cm=confusion_matrix(y_train, svm_model.predict(X_train))
         confusion_matrix_lda = pandas.DataFrame(cm, index = ['Negativos', 'Positivos'], columns = ['Pre
In [40]:
          visão dos negativos','Previsão dos positivos'] )
          confusion_matrix_lda['Total'] = 1
          confusion\_matrix\_lda['Total'][0] = cm[0][0] + cm[0][1]
          confusion_matrix_lda['Total'][1] = cm[1][0] + cm[1][1]
In [41]:
         confusion_matrix_lda
Out[41]:
                   Previsão dos negativos Previsão dos positivos Total
                                                          1108
                                  1105
          Negativos
           Positivos
                                    22
                                                     1086 1108
In [42]:
         TP = confusion_matrix_lda['Previsão dos positivos'][1]
          dfTP = pandas.DataFrame(TP, index = ['Positivos verdadeiros'], columns = ['Quantidade acertos'
          ])
          TP
Out[42]: 1086
```

```
In [43]:
         TN = confusion matrix lda['Previsão dos negativos'][0]
         dfTN = pandas.DataFrame(TN, index = ['Verdadeiro Negativo'], columns = ['Quantidade acertos']
         TN
Out[43]: 1105
In [44]: | FP = confusion_matrix_lda['Previsão dos positivos'][0]
         dfFP = pandas.DataFrame(FP, index = ['Falso Positivo'], columns = ['Quantidade acertos'] )
Out[44]: 3
In [45]: FN = confusion_matrix_lda['Previsão dos negativos'][1]
         dfFN = pandas.DataFrame(FN, index = ['Negativos Falsos'], columns = ['Quantidade acertos'] )
Out[45]: 22
In [46]: print(f"accuracy score: {accuracy_score(y_train, svm_pred):.4f}\n")
         svmAccuracy = accuracy_score(y_train, svm_pred)
         accuracy score: 0.9887
In [47]: import plot as plot
         cm=confusion_matrix(y_train, svm_model.predict(X_train))
         #Plot the confusion matrix
         plt.rcParams['figure.figsize'] = (10,5)
         sb.set(font_scale=1.5)
         sb.heatmap(cm, annot=True, fmt='g')
         plt.show()
                                                                              - 1000
                                                         3
                          1105
          0
                                                                              - 800
                                                                              -600
                                                                              -400
                           22
                                                       1086
                                                                               200
                            0
                                                         1
```

## Metricas Report: svm

## **Curva ROC: SVM**

```
In [53]: svm_pred_prob = svm_model.predict_proba(X_test)[:, 1]
In [54]: svm_fpr, svm_tpr, thresholds = roc_curve(y_test, svm_pred_prob)
In [55]: plot_roc_curve(svm_fpr, svm_tpr,'SVM')
```



## AUC (área sob a curva) da Curva ROC : SVM

AUC ou Area Under the Curve é a porcentagem do gráfico do ROC que está abaixo da curva. AUC é útil como um único número de resumo do desempenho do classificador.

```
In [56]: print(roc_auc_score(y_test, svm_pred_prob))
SVM_Auc=roc_auc_score(y_test, svm_pred_prob)

0.9981772120612952
```

# Carregando o modelo Máquina de Naive Bayes

```
In [57]: from sklearn.naive_bayes import GaussianNB
nb_model = GaussianNB()
```

## Treinamento e teste do modelo: NB.

```
In [58]: nb_model.fit(X_train, y_train)
Out[58]: GaussianNB(priors=None, var_smoothing=1e-09)
In [59]: nb_pred = nb_model.predict(X_train)
```

## Modelo de avaliação de métricas. NB.

## Precisão Geral (Accuracy): NB.

```
In [60]: #get accuracy
print(f"accuracy score: {accuracy_score(y_train, nb_pred):.4f}\n")
nb_accuracy_testdata = accuracy_score(y_train, nb_pred)
accuracy_score: 0.9057
```

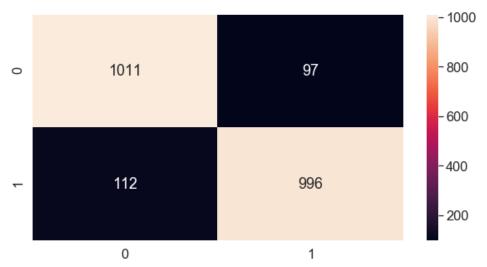
### Matriz de confusão: NB.

```
In [61]: cm=confusion_matrix(y_train, nb_model.predict(X_train))
    confusion_matrix_lda = pandas.DataFrame(cm, index = ['Negativos', 'Positivos'], columns = ['Pre
    visão dos negativos', 'Previsão dos positivos'] )
    confusion_matrix_lda['Total'] = 1
    confusion_matrix_lda['Total'][0] = cm[0][0] + cm[0][1]
    confusion_matrix_lda['Total'][1] = cm[1][0] + cm[1][1]
    confusion_matrix_lda
```

#### Out[61]:

|           | Previsão dos negativos | Previsão dos positivos | Total |
|-----------|------------------------|------------------------|-------|
| Negativos | 1011                   | 97                     | 1108  |
| Positivos | 112                    | 996                    | 1108  |

```
In [62]: import plot as plot
    cm=confusion_matrix(y_train, nb_model.predict(X_train))
#Plot the confusion matrix
    plt.rcParams['figure.figsize'] = (10,5)
    sb.set(font_scale=1.5)
    sb.heatmap(cm, annot=True, fmt='g')
    plt.show()
```

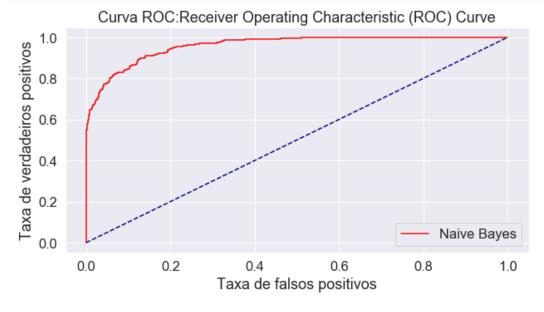


## Metricas Report: NB.

```
In [63]: print(f"Classification Report: \n \tPrecision: {precision score(y train, nb pred)}\n\tRecall S
         core: {recall_score(y_train,nb_pred)}\n\tF1 score: {f1_score(y_train, nb_pred)}\n")
         Classification Report:
                 Precision: 0.9112534309240622
                 Recall Score: 0.8989169675090253
                 F1 score: 0.9050431621990005
In [64]:
         TP = confusion matrix lda['Previsão dos positivos'][1]
         dfTP = pandas.DataFrame(TP, index = ['Positivos verdadeiros'], columns = ['Quantidade acertos'
         ] )
         TP
Out[64]: 996
In [65]:
         TN = confusion matrix lda['Previsão dos negativos'][0]
         dfTN = pandas.DataFrame(TN, index = ['Verdadeiro Negativo'], columns = ['Quantidade acertos']
         TN
Out[65]: 1011
In [66]: FP = confusion_matrix_lda['Previsão dos positivos'][0]
         dfFP = pandas.DataFrame(FP, index = ['Falso Positivo'], columns = ['Quantidade acertos'] )
Out[66]: 97
In [67]: FN = confusion matrix lda['Previsão dos negativos'][1]
         dfFN = pandas.DataFrame(FN, index = ['Negativos Falsos'], columns = ['Quantidade acertos'] )
         FΝ
Out[67]: 112
```

### Curva ROC: NB.

```
In [73]: nb_pred_prob = nb_model.predict_proba(X_test)[:, 1]
In [74]: nb_fpr, nb_tpr, thresholds = roc_curve(y_test, nb_pred_prob)
In [75]: plot_roc_curve(nb_fpr, nb_tpr,'Naive Bayes')
```



## AUC (área sob a curva) da Curva ROC : NB.

```
In [76]: print(roc_auc_score(y_test, nb_pred_prob))
NB_Auc=roc_auc_score(y_test, nb_pred_prob)
```

0.9599516277099075

# Comparativo entre os modelos

## Carregar o modelo de Árvore Decisão

```
In [78]: filename = '.\\baseDados\\cart.jss'
    infile = open(filename,'rb')
    cart_dict = pickle.load(infile)
    infile.close()
    CART_auc= cart_dict['Auc']
    CART_pred_prob= cart_dict['y_pred_prob']

In [79]: #print(cart_dict)

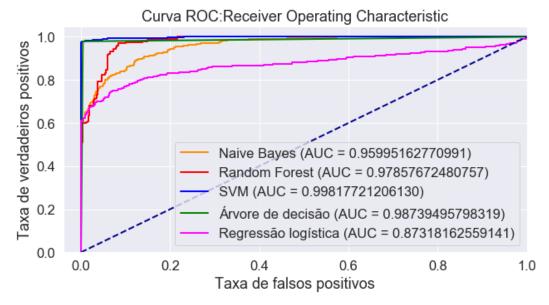
In [80]: #print(cart_dict)
    cart_fpr, cart_tpr, thresholds = roc_curve(y_test, CART_pred_prob)
```

## Carregar o modelo de Regressão logística

```
In [81]: filenamerl = '.\\baseDados\\regressaologitica.jss'
    infile = open(filenamerl, 'rb')
    rlog_dict = pickle.load(infile)
    infile.close()
    #print(rlog_dict)
    rlog_auc= rlog_dict['Auc']
    rlog_pred_prob= rlog_dict['y_pred_prob']
In [82]: rlog_fpr, rlog_tpr, thresholds = roc_curve(y_test, rlog_pred_prob)
```

# Mostra o gráfico comparativo

```
In [83]:
         lw = 2
         plt.figure()
         plt.rcParams['figure.figsize'] = (12,6)
         plt.plot(nb_fpr, nb_tpr, color='darkorange', lw=lw, label='Naive Bayes (AUC = %0.14f)' % NB_A
         plt.plot(rf_fpr, rf_tpr , color='red', lw=lw, label='Random Forest (AUC = %0.14f)' % RF_Auc)
         plt.plot(svm_fpr, svm_tpr , color='blue', lw=lw, label='SVM (AUC = %0.14f)' % SVM_Auc)
         plt.plot(cart_fpr, cart_tpr , color='green', lw=lw, label='Árvore de decisão (AUC = %0.14f)'
         % CART_auc)
         plt.plot(rlog_fpr, rlog_tpr , color='magenta', lw=lw, label='Regressão logística (AUC = %0.14
         f)' % rlog auc)
              ----- linha central-----
         plt.plot([0, 1], [0, 1], color='darkblue', lw=lw, linestyle='--')
         plt.xlabel('Taxa de falsos positivos')
         plt.ylabel('Taxa de verdadeiros positivos')
         plt.title('Curva ROC:Receiver Operating Characteristic')
         sb.set(font_scale=1.5)
         plt.legend()
         plt.xlim([-0.04, 1.0])
         plt.ylim([0.0, 1.05])
         plt.show()
         plt.savefig('roc_auc.png')
         plt.close()
```



```
In [84]: plt.subplots_adjust(left=0.1, right=0.9, top=0.9, bottom=0.1)
```

<Figure size 864x432 with 0 Axes>

# Comparando as métricas dos modelos Acurácia, Precisão e AUC.

```
In [85]: #print(cart_dict)
```

```
In [86]: | dfresultado=pd.DataFrame.from_dict(dict([('Regressão Logística',[rlog_dict['Accuracy'],
                                                                rlog dict['Precision'],
                                                                rlog_dict['Specificity'],
                                                                rlog_dict['F1Score'],
                                                               rlog_dict['Recall'],
                                                               rlog_dict['Auc']]),
                                      ('Arvore de decisão',[cart_dict['Accuracy'],
                                                                cart_dict['Precision'],
                                                               cart_dict['Specificity'],
                                                               cart_dict['F1Score'],
                                                               cart_dict['Recall'],
                                                                cart_dict['Auc']]),
                                      ('Random Forest', [RF_Accuracy, rfPrecision, rfSpecificity,rfF1Sco
         re,rfRecall,RF_Auc]),
                                      ('SVM', [svmAccuracy, svmPrecision, svmSpecificity,svmF1_score,svm
         Recall,SVM_Auc]),
                                      ('Naive Bayes', [nb_accuracy_testdata, nbPrecision, nbSpecificity,
         nbF1_score,nbRecall,NB_Auc])]),
                                      orient='index', columns=['Accuracy', 'Precision', 'Specificity',
          'F1Score', 'Recall', 'AUC'])
```

In [87]: dfresultado

#### Out[87]:

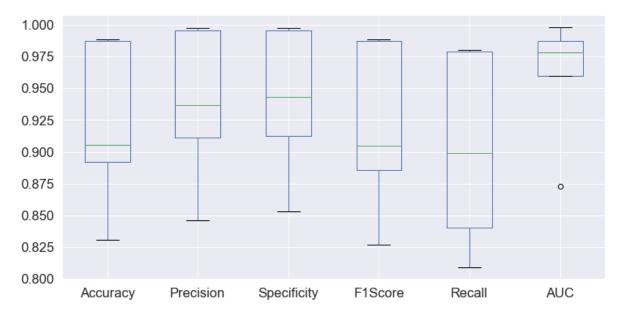
|                     | Accuracy | Precision | Specificity | F1Score  | Recall   | AUC      |
|---------------------|----------|-----------|-------------|----------|----------|----------|
| Regressão Logística | 0.830882 | 0.846154  | 0.852941    | 0.827068 | 0.808824 | 0.873182 |
| Arvore de decisão   | 0.987395 | 0.995726  | 0.995798    | 0.987288 | 0.978992 | 0.987395 |
| Random Forest       | 0.891807 | 0.936768  | 0.943277    | 0.885936 | 0.840336 | 0.978577 |
| SVM                 | 0.988718 | 0.997245  | 0.997292    | 0.988621 | 0.980144 | 0.998177 |
| Naive Bayes         | 0.905686 | 0.911253  | 0.912455    | 0.905043 | 0.898917 | 0.959952 |

In [88]: dfresultado.describe()

## Out[88]:

|       | Accuracy | Precision | Specificity | F1Score  | Recall   | AUC      |
|-------|----------|-----------|-------------|----------|----------|----------|
| count | 5.000000 | 5.000000  | 5.000000    | 5.000000 | 5.000000 | 5.000000 |
| mean  | 0.920898 | 0.937429  | 0.940353    | 0.918791 | 0.901443 | 0.959456 |
| std   | 0.067457 | 0.063232  | 0.060712    | 0.069372 | 0.078305 | 0.050222 |
| min   | 0.830882 | 0.846154  | 0.852941    | 0.827068 | 0.808824 | 0.873182 |
| 25%   | 0.891807 | 0.911253  | 0.912455    | 0.885936 | 0.840336 | 0.959952 |
| 50%   | 0.905686 | 0.936768  | 0.943277    | 0.905043 | 0.898917 | 0.978577 |
| 75%   | 0.987395 | 0.995726  | 0.995798    | 0.987288 | 0.978992 | 0.987395 |
| max   | 0.988718 | 0.997245  | 0.997292    | 0.988621 | 0.980144 | 0.998177 |

```
In [89]: boxplot = dfresultado.boxplot()
```



```
In [90]: Amplitudedic = {}
    Varianciadic = {}
    CoeficienteVardic = {}
    juntar = {}
    IntervaloInterquartildic = {}
    colunas=['Accuracy', 'Precision', 'Specificity', 'F1Score', 'Recall','AUC']
    for x in colunas:
        juntar[x] = dfresultado[x].std()/1
        Amplitudedic[x]=dfresultado[x].max() - dfresultado[x].min()
        Varianciadic[x] = dfresultado[x].var()
        CoeficienteVardic[x] = (dfresultado[x].std()/dfresultado[x].mean()) * 100
        IntervaloInterquartildic[x] = dfresultado[x].quantile(q=0.75) - dfresultado[x].quantile(q=0.25)
```

#### Out[91]:

|   | quantitativas | Amplitude |
|---|---------------|-----------|
| 0 | Accuracy      | 0.157836  |
| 1 | Precision     | 0.151091  |
| 2 | Specificity   | 0.144351  |
| 3 | F1Score       | 0.161553  |
| 4 | Recall        | 0.171321  |

```
In [92]: dfstd = pandas.DataFrame.from_dict(juntar, orient="index").reset_index()
    dfstd.columns = ["quantitativas","std"]
    dfstd.head()
```

## Out[92]:

|   | quantitativas | std      |
|---|---------------|----------|
| 0 | Accuracy      | 0.067457 |
| 1 | Precision     | 0.063232 |
| 2 | Specificity   | 0.060712 |
| 3 | F1Score       | 0.069372 |
| 4 | Recall        | 0.078305 |

#### Out[93]:

|   | quantitativas | Variancia |
|---|---------------|-----------|
| 0 | Accuracy      | 0.004550  |
| 1 | Precision     | 0.003998  |
| 2 | Specificity   | 0.003686  |
| 3 | F1Score       | 0.004812  |
| 4 | Recall        | 0.006132  |

#### Out[94]:

|   | quantitativas | Coef_Var_% |
|---|---------------|------------|
| 0 | Accuracy      | 7.325174   |
| 1 | Precision     | 6.745293   |
| 2 | Specificity   | 6.456339   |
| 3 | F1Score       | 7.550318   |
| 4 | Recall        | 8.686597   |

#### Out[95]:

|   | quantitativas | Intervalo_Interquartil |
|---|---------------|------------------------|
| 0 | Accuracy      | 0.095588               |
| 1 | Precision     | 0.084473               |
| 2 | Specificity   | 0.083343               |
| 3 | F1Score       | 0.101352               |
| 4 | Recall        | 0.138655               |

In [96]: dfresultado\_frame=pandas.merge(dfAmplitude,dfVariancia,how='right',on='quantitativas')
 dfresultado\_frame=pandas.merge(dfresultado\_frame,dfCoeficiente,how='right',on='quantitativas')
 dfresultado\_frame=pandas.merge(dfresultado\_frame,IntervaloInterquartil,how='right',on='quantit
 ativas')
 dfresultado\_frame=pandas.merge(dfresultado\_frame,dfstd,how='right',on='quantitativas')
 dfresultado\_frame

#### Out[96]:

|   | quantitativas | Amplitude | Variancia | Coef_Var_% | Intervalo_Interquartil | std      |
|---|---------------|-----------|-----------|------------|------------------------|----------|
| 0 | Accuracy      | 0.157836  | 0.004550  | 7.325174   | 0.095588               | 0.067457 |
| 1 | Precision     | 0.151091  | 0.003998  | 6.745293   | 0.084473               | 0.063232 |
| 2 | Specificity   | 0.144351  | 0.003686  | 6.456339   | 0.083343               | 0.060712 |
| 3 | F1Score       | 0.161553  | 0.004812  | 7.550318   | 0.101352               | 0.069372 |
| 4 | Recall        | 0.171321  | 0.006132  | 8.686597   | 0.138655               | 0.078305 |
| 5 | AUC           | 0.124996  | 0.002522  | 5.234431   | 0.027443               | 0.050222 |

| Fim da avaliação do modelo. |  |  |
|-----------------------------|--|--|
|                             |  |  |
| Fim da avaliação do modelo. |  |  |